ESCUELA POL ITÉCNICA NACIONAL

Facultad de Ingeniería de Sistemas · Carrera de Ciencia de Datos e Inteligencia Artificial

I N F O R M E D E P R ÁC T I C A N . º 1

Consolidación de reportes de ventas (CSV, JSON y Excel)

Tópico Herramientas software para Estadística (Python y R) del PEA · Asignatura IDSD422 — Estadística y Programación para Ciencia de Datos I

Estudiante(s): Emily Paola Pacheco Jiménez — emypao2006-wq

Docente: Christian Suárez

Período académico: 2026-B

Fecha de entrega: 19/10/2026

Repositorio (fork): https://github.com/emypao2006-wq/IDSD422-lab1-lectura-datos

1 · Introducción

El equipo de Business Intelligence de RetailAndina S.A. recibe reportes semanales de ventas de tres sistemas: ERP de sucursales, API de la plataforma de fidelización y consolidado de Finanzas. Estos reportes se presentan en formatos CSV, JSON y Excel, por lo que es importante verificar que contengan la misma información y estén organizados correctamente antes de realizar su análisis.

En esta práctica utilicé Google Colab para trabajar con Python y Posit Cloud para R. Mediante estas herramientas inspeccioné los primeros registros, las dimensiones y los tipos de datos de cada archivo. Además, calculé indicadores como la venta promedio por sucursal, el ticket promedio, las sucursales con mayor y menor venta y la región con mayores ventas totales. Los resultados permiten conocer el desempeño comercial de las sucursales y proporcionan información útil para la toma de decisiones.

2 · Objetivos

2.1 Objetivo general

- Analizar los reportes de ventas de los tres formatos presentados CSV, JSON y Excel mediante Python y R, para así corroborar su estructura y calcular los indicadores.

2.2 Objetivos Específicos

- Leer los archivos CSV, JSON y Excel mediante Google Colab para Python y Posit Cloud para R.
- Verificar los primeros registros, las dimensiones y el tipo de dato de cada archivo para constatar la consistencia.
- Procesar los datos de ventas y clientes por medio de la creación de una columna derivada permitiendo calcular el ticket por cliente.
- Calcular e identificar los indicadores comerciales de sucursales con mayor y menor ventas, al igual que la región con mayores ventas.

3 · Desarrollo de la práctica

3.1 Utilización de las herramientas

Utilicé Google Colab para ejecutar los códigos en Python y Posit Cloud para trabajar con R. En Colab cargué los archivos ventas.csv, ventas.json y ventas.xlsx y los organicé en la carpeta data, mientras que en Posit Cloud subí directamente esa carpeta.

En Python trabajé con la biblioteca pandas y el módulo json; en R utilicé los paquetes readr, readxl y jsonlite. Inicialmente, ejecuté los códigos con las rutas de Colab y posteriormente

las adapté a data/ para permitir su ejecución desde la raíz del repositorio. Finalmente, registré los avances mediante commits en GitHub.

3.2 Lectura de los archivos en Python

En Google Colab utilicé pd.read_csv() para CSV, json.load() y pd.json_normalize() para JSON, y pd.read_excel() para Excel, seleccionando la hoja ventas. (pandas development team, s. f.)

Código

```
# Leé el archivo CSV

ventas = pd.read_csv("/content/data/ventas.csv")

# Leé el archivo Excel

ventas = pd.read_excel("/content/data/ventas.xlsx", sheet_name="ventas")

# Leé el archivo JSON

with open("/content/data/ventas.json", encoding="utf-8") as f:

    datos = json.load(f)

ventas = pd.json_normalize(datos)
```

Utilicé head(), shape y dtypes para inspeccionar los archivos. Los tres presentaron cinco filas y cuatro columnas: sucursal, region, ventas y clientes. Las variables de texto se identificaron como object y las numéricas como int64.

3.3 Lectura de los archivos en R

En Posit Cloud utilicé read_csv() para CSV, fromJSON() para JSON y read_excel() para Excel. También convertí los datos JSON en un data.frame. (Wickham et al., s. f.; Wickham & Bryan, s. f.; Ooms, s. f.)

Código

```
# Leé el archivo CSV

ventas <- readr::read_csv("data/ventas.csv")

# Leé el archivo JSON

ventas <- jsonlite::fromJSON("data/ventas.json")

ventas <- as.data.frame(ventas)
```

```
# Leé el archivo Excel

ventas <- readxl::read_excel("data/ventas.xlsx",  sheet = "ventas")
```

Con head(), dim() y str() comprobé que los tres archivos contenían cinco filas y cuatro columnas. Las variables de texto se identificaron como chr y las numéricas como int, num o dbl, según la función de lectura.

3.4 Inspección y cálculo de indicadores

Utilicé los datos del CSV para crear la columna ticket, dividiendo las ventas entre el número de clientes. Posteriormente, calculé los promedios, agrupé las ventas por región e identifiqué los valores máximos y mínimos. En Python utilicé funciones como groupby(), mean(), sum(), idxmax() e idxmin(). En R empleé aggregate(), mean(), sum(), which.max() y which.min().

Código Python

```
# Crear columna ticket

ventas["ticket"] = ventas["ventas"] / ventas["clientes"]

# Venta promedio por sucursal

print(ventas.groupby("sucursal")["ventas"].mean())

# Ticket promedio general

print(ventas["ventas"].sum() / ventas["clientes"].sum())

# Ventas por región

ventas_region = ventas.groupby("region")["ventas"].sum()

print(ventas_region)
```

Código R

```
# Crear columna ticket

ventas$ticket <- ventas$ventas / ventas$clientes

# Venta promedio por sucursal

promedio_sucursal <- aggregate(ventas$ventas,by = list(sucursal =ventas$sucursal),

                               FUN = mean)

# Ticket promedio general
```

```
ticket_promedio <- sum(ventas$ventas) / sum(ventas$clientes)

# Region con mayor venta total

ventas_region <- aggregate(ventas ~ region,

                           data = ventas, FUN = sum)

ventas_region

ventas_region$region[

  which.max(ventas_region$ventas)

]
```

Guayaquil Centro registró la mayor venta, con $15.200, y Cuenca la menor, con $8.540. El ticket promedio general fue de $38,07. Por regiones, Sierra alcanzó $30.860 y Costa $29.180.

3.5 Interpretación de los datos

- ¿Cuántas filas y columnas tiene la tabla en cada uno de los tres formatos?

¿Fue igual en los tres? ¿Por qué?

Los archivos CSV, JSON y Excel presentaron cinco filas y cuatro columnas. Sus dimensiones coincidieron porque representan el mismo reporte semanal de ventas, aunque provienen de distintos sistemas.

- ¿Qué tipo de datos se infirió para ventas y clientes? ¿Qué indicaría que

salieran como texto?

En Python se identificaron como int64 y en R como tipos numéricos (int o num). Si aparecieran como texto, podría indicar la presencia de caracteres no numéricos o problemas de formato que dificultarían los cálculos.

- En Python, ¿qué estructura devuelve json.load y por qué hay que "aplanarla"?

json.load() devuelve estructuras de Python, como listas y diccionarios. Cuando existen datos anidados, aplanarlos permite convertirlos en columnas independientes. Utilicé pd.json_normalize() para organizar los registros en un DataFrame y facilitar su análisis.

- ¿Para qué sirve indicar sheet_name/sheet al leer Excel?

Permite seleccionar la hoja que contiene los datos necesarios. En esta práctica indiqué ventas para asegurar que se leyera la información correcta.

- ¿Qué diferencia ves entre leer en Python y leer en R (conceptos, no sintaxis)?

Python utiliza bibliotecas como pandas, mientras que R dispone de paquetes como readr, jsonlite y readxl. También presentan diferencias en los tipos de datos inferidos y en la visualización de resultados, aunque ambos permitieron realizar el mismo análisis.

4 · ¿Qué aprendí con esta práctica?

Con esta práctica reforcé mis conocimientos sobre la lectura de archivos en Python y aprendí nuevas funciones para trabajar con JSON y Excel. También conocí el lenguaje R, que me pareció interesante porque, aunque tiene algunas similitudes con Python, presenta diferencias en la forma de trabajar y mostrar los resultados. Comprendí que cada formato almacena la información de manera distinta, pero que es posible obtener los mismos resultados si los datos coinciden y se procesan correctamente.

Además, aprendí a crear una columna derivada, como ticket, para obtener nuevos valores a partir de los datos existentes. También reforcé el uso de funciones para calcular promedios e identificar valores máximos y mínimos. Conocí Google Colab y Posit Cloud, herramientas que me resultaron fáciles de utilizar, aunque preferí la presentación de resultados de Google Colab.

La principal dificultad que encontré fue el manejo de las rutas de los archivos en Google Colab, ya que inicialmente no funcionaban como esperaba. Lo solucioné utilizando las rutas correspondientes al entorno y posteriormente las adapté para ejecutar los scripts desde la carpeta principal del repositorio de GitHub.

5 · Conclusiones

1. Se logró leer los archivos en los tres formatos CSV, JSON y Excel utilizando Python y R. Los tres formatos presentaron cinco filas y cuatro columnas. Además, al revisar los registros mostrados, observé que los valores de sucursales, regiones, ventas y clientes coincidían, a pesar de las diferencias en los formatos y los tipos de datos inferidos.
2. Al obtener el tipo de datos numéricos me permitió comprobar que las variables ventas y clientes se las puede utilizar para la creación de la columna ticket, la cual ayudo para calcular los indicadores, obteniendo como resultado de ticket promedio general $38,07.
3. Tras el análisis realizado se informa a la gerencia de RetailAndina S.A que Guayaquil Centro registró la mayor venta con $15200, mientras Cuenca presentó la menor con $8540. La región Sierra alcanzó el mayor volumen de ventas con $30860. Sin embargo, estos resultados corresponden únicamente a las cinco sucursales y al período semanal analizado, por lo que no permiten predecir el comportamiento de las ventas futuras.

4. **Recomendación:** Se recomienda a RetailAndina S.A. verificar la consistencia de los datos antes de realizar futuros análisis y establecer un formato estandarizado para facilitar la integración de los reportes provenientes de los diferentes sistemas.

6 · Bibliografía

Ooms, J. (s. f.). *jsonlite: A simple and robust JSON parser and generator for R*. CRAN. Recuperado el 19 de octubre de 2026, de https://cran.r-project.org/package=jsonlite

pandas development team. (s. f.). *pandas.read_csv*. pandas documentation.Recuperado el 19 de octubre de 2026, de https://pandas.pydata.org/docs/reference/api/pandas.read_csv.html

Suárez, C. (2026). *Laboratorio 1: Consolidación de reportes de ventas* [Repositorio de código]. GitHub. https://github.com/christian-suarez1979/IDSD422-lab1-lectura-datos

Wickham, H., Hester, J., & Bryan, J. (s. f.). *Read a delimited file (including CSV and TSV) into a tibble*. readr. Recuperado el 19 de octubre de 2026, de https://readr.tidyverse.org/reference/read_delim.html

Wickham, H., & Bryan, J. (s. f.). *Read xls and xlsx files*. readxl. Recuperado el 19 de octubre de 2026, de https://readxl.tidyverse.org/reference/read_excel.html

Declaración del uso de inteligencia artificial

Durante el desarrollo de esta práctica utilicé ChatGPT como herramienta de apoyo para resolver dudas relacionadas con fallas de ejecución que me aparecían las cuales eran por errores al momento de escribir, revisar la ortografía del documento y también lo utilicé al momento de querer hacer commits al repositorio porque no me acordaba claramente como realizar.

Anexos

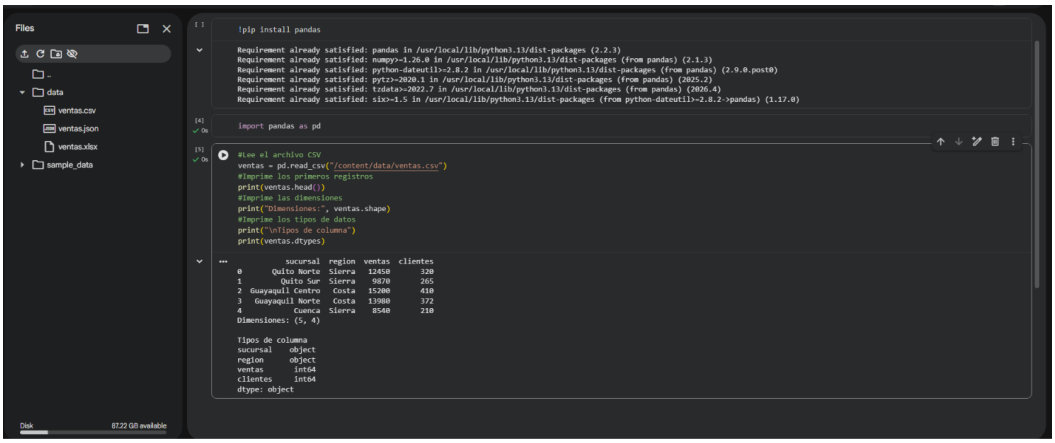


Figura 1. Lectura del archivo CSV en Google Colab (Python) y visualización de sus datos (primeros registros, dimensiones, tipo de dato).

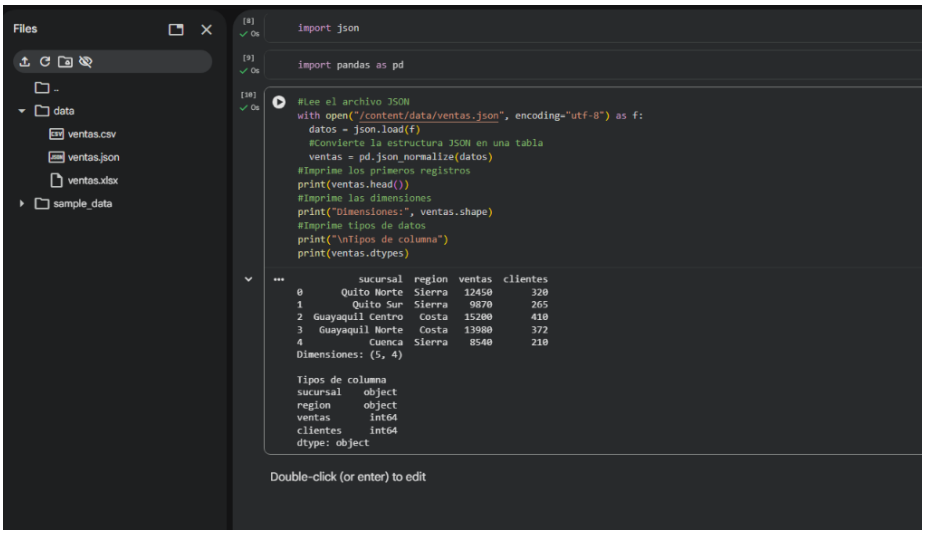


Figura 2.Lectura del archivo JSON en Google Colab (Python), conversión a DataFrame y visualización de sus datos (primeros registros, dimensiones, tipo de dato).



Figura 3.Lectura del archivo Excel en Google Colab (Python), seleccionando la hoja ventas y visualización de sus datos (primeros registros, dimensiones, tipo de dato).

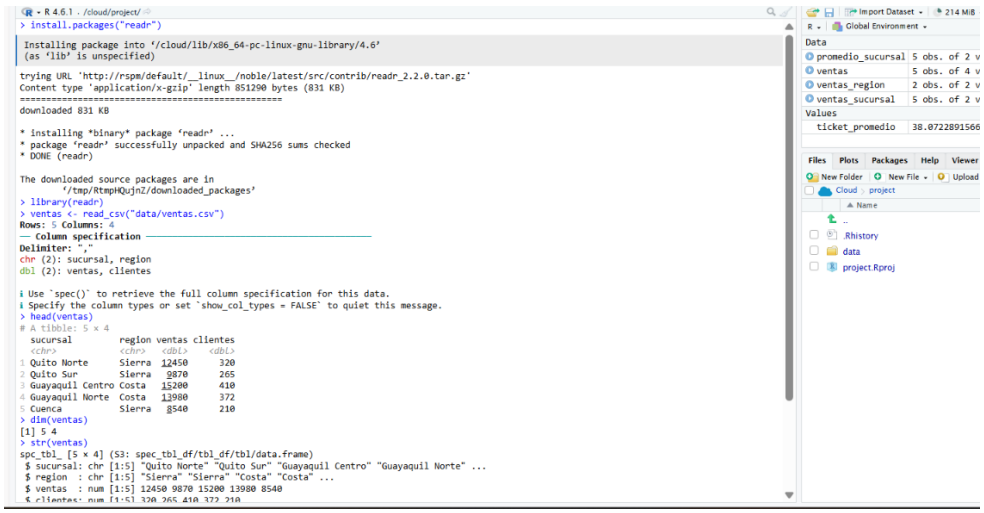


Figura 4.Lectura del archivo CSV en Posit Cloud (R) y visualización de sus datos (primeros registros, dimensiones, tipo de dato).

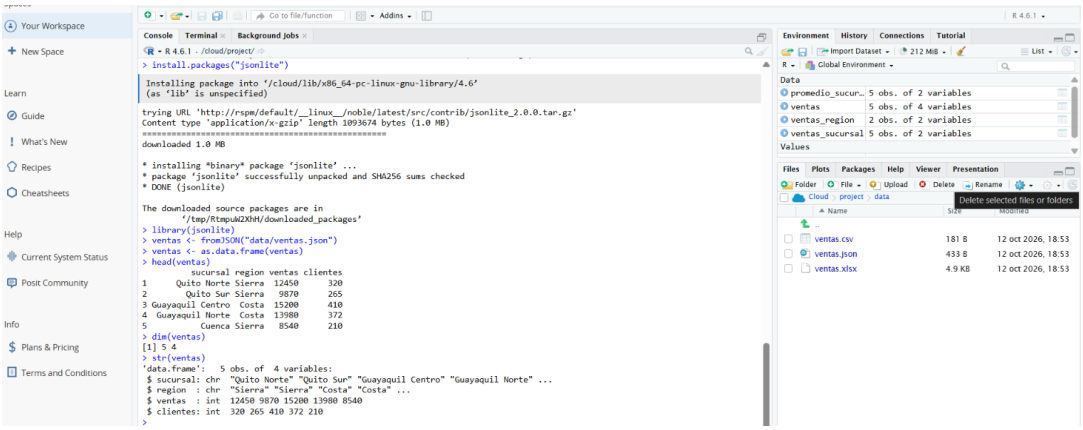


Figura 5.Lectura del archivo JSON en Posit Cloud (R) , conversión a data.frame y visualización de sus datos (primeros registros, dimensiones, tipo de dato).

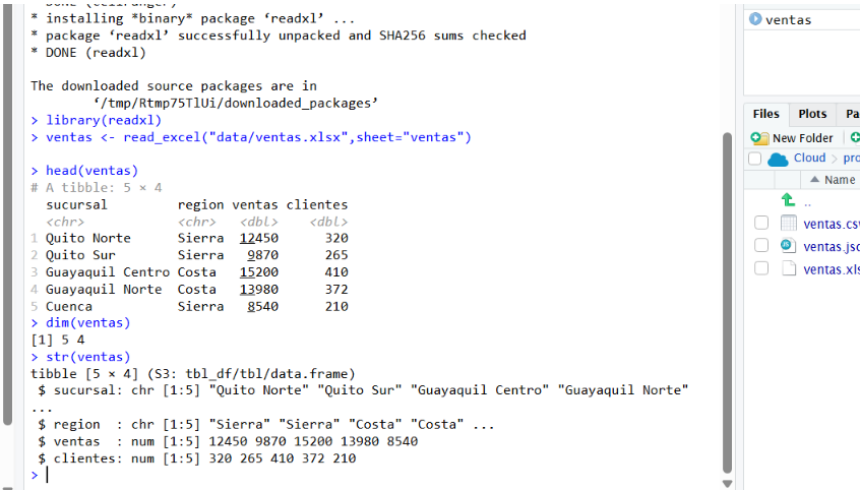


Figura 6.Lectura del archivo Excel en Posit Cloud (R), seleccionando la hoja ventas y visualización de sus datos (primeros registros, dimensiones, tipo de dato).

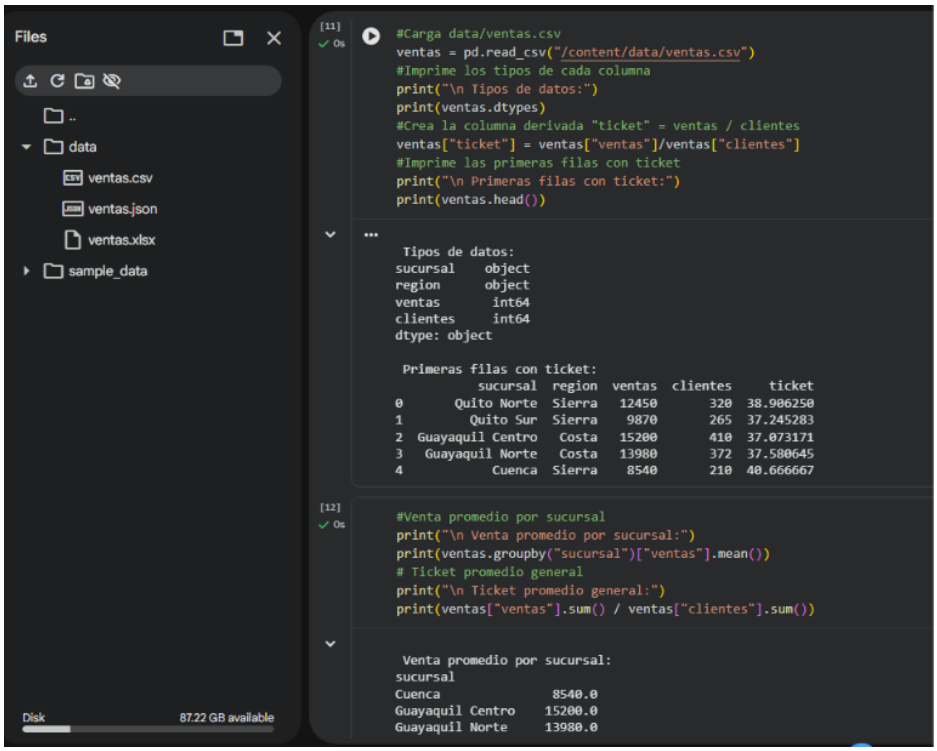


Figura 7.Creación de la columna ticket y cálculo de indicadores en Python

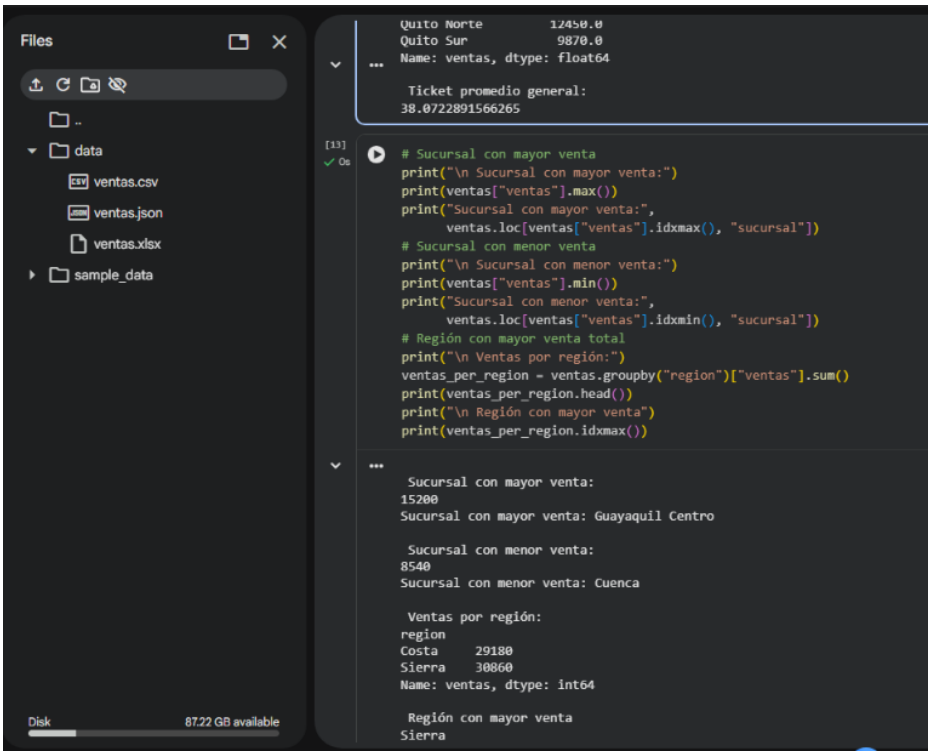


Figura 8.Sucursales y regiones con mayores y menores ventas en Python.

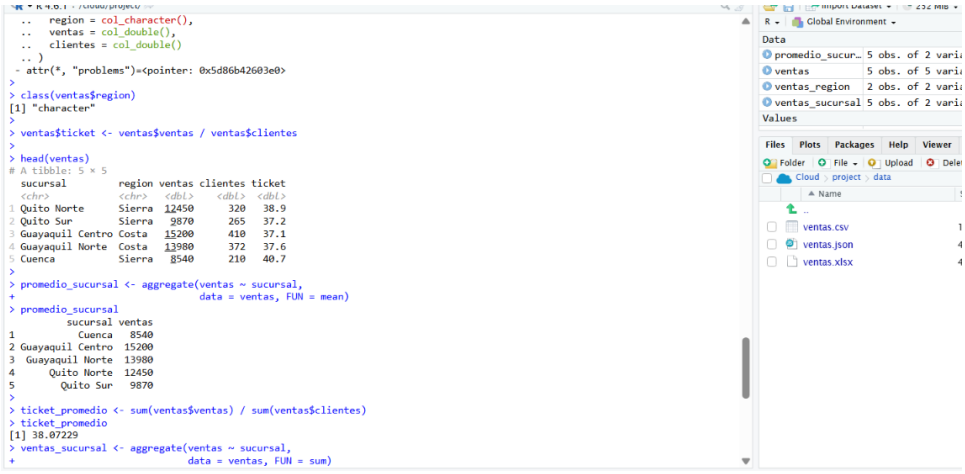


Figura 9. Creación de la columna ticket y cálculo de indicadores en R

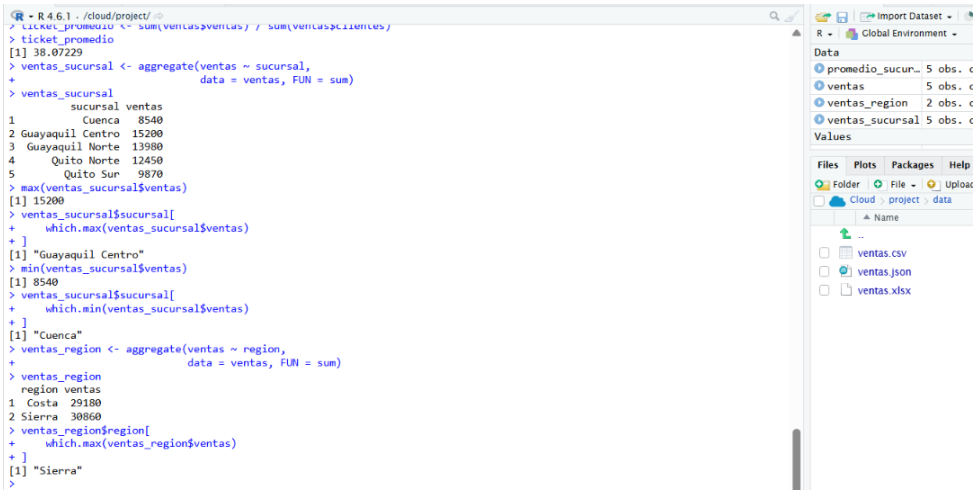


Figura 10.Sucursales y regiones con mayores y menores ventas en R.